

Reinforcement Learning - Übung 02

Gruppe 4 - Amos Mohr, Daniel Maier, Sifan Zhu, Tommy Kiss

30. Mai 2026

1)


Siehe Implementierung!

2)

Siehe Implementierung!


3)

3.1)




Je größer γ , desto mehr Iterationen bis zur Konvergenz. Bei $\gamma = 0.99$ explodiert der Aufwand auf ungefähr 700 Iterationen, da zukünftige Rewards stärker gewichtet werden und sich die Werte langsamer durch das Grid ausbreiten.

3.2)



Erst ab $\gamma \approx 0.8$ lernt die Policy eine sinnvolle Strategie. Darunter ist der Zeithorizont zu kurz, um die hohen Rewards im Grid überhaupt zu “sehen”, weshalb der kumulierte Reward flach bei ungefähr 5 bleibt.

3.3)





Man sieht, dass für $\gamma = 0.85$ der beste $score = \frac{reward}{iterations}$ entsteht, d.h. in diesem Fall ist das beste Preis-Leistungsverhältnis gegeben. Dort liegt der kumulierte Reward bereits nahe am Maximum, während der Rechenaufwand mit unter 100 Iterationen noch überschaubar bleibt. Der Ausreißer $\gamma = 0$ ergibt zwar wegen der fast sofortigen Konvergenz einen guten Score, aber wie in 3.2 gesehen keine gute Policy.

4)

Wir haben es nicht ersetzt sondern neu implementiert, siehe Zelle mit Aufgabe 4. Dort werden die nötigen Parameter konstruiert, die Funktion aufgerufen und das policy-Objekt so rekonstruiert, dass wir es plotten können. Abgesehen davon, dass die Übergabeformate abweichen, muss man hauptsächlich ein Objekt zusätzlich übergeben, dass die Transitionswahrscheinlichkeiten modelliert. Diese sind bei uns implizit und stehen in der ValueIteration Funktion. Wir verwenden den Spezialfall, dass alle Transitionen deterministisch sind, also ist die entstehende Matrix (pro Aktion) eine Matrix mit einer 1 und sonst nur 0en in jeder Zeile. Man sieht, dass die gefundene Policy die gleiche ist.

5)





Man sieht hier eine Darstellung der durchschnittlichen Rewards per Episode sowie der Rewards pro Step, per Episode über je 100 Episoden mit 2000 Steps und $\gamma = 0.9$, in Abhängigkeit von ϵ . Offenbar ist der durchschnittliche Reward relativ unempfindlich gegen den Parameter ϵ , solange er nicht extrem am Rand des Intervalls liegt und ungefähr ≤ 0.85 ist. Beim Reward pro Step zeigt sich dagegen eine klare Präferenz für kleine Werte ≥ 0.07 , mit einem Maximum bei 0.21 mit durchschnittlichem Reward pro Step von 1.92.